

Regressão Logística: Função Custo Simplificada e Método do Gradiente



Na aula anterior, definimos a **função perda** e a **função custo** para a Regressão Logística.

Nesta aula, iremos simplificar a definição da função custo e aplicar o Método do Gradiente para encontrar seu mínimo global.

Na aula passada, vimos que a **Função de perda** para Regressão Logística é dada por

$$L\left(f_{\vec{w},b}\left(\vec{x}^{(i)}\right), y^{(i)}\right) = \begin{cases} -\log\left(f_{\vec{w},b}\left(\vec{x}^{(i)}\right)\right) & , \text{ se } y^{(i)} = 1 \\ -\log\left(1 - f_{\vec{w},b}\left(\vec{x}^{(i)}\right)\right) & , \text{ se } y^{(i)} = 0 \end{cases}$$

OBS: $y^{(i)}$ é sempre 1 ou 0 (tumor maligno ou não)

Note que é possível simplificar, escrevendo da seguinte forma equivalente:

$$L\left(f_{\vec{w},b}\left(\vec{x}^{(i)}\right), y^{(i)}\right) = -y^{(i)} \log\left(f_{\vec{w},b}\left(\vec{x}^{(i)}\right)\right) - (1 - y^{(i)}) \log\left(1 - f_{\vec{w},b}\left(\vec{x}^{(i)}\right)\right)$$

For the simplified loss function:

$$L(f_{\mathbf{w},b}(\mathbf{x}^{(i)}), y^{(i)}) = -y^{(i)}\log(f_{\mathbf{w},b}(\mathbf{x}^{(i)})) - (1 - y^{(i)})\log(1 - f_{\mathbf{w},b}(\mathbf{x}^{(i)}))$$

if the target $y^{(i)} = 1$, then what does this expression simplify to?

☒ $-\log(f_{\mathbf{w},b}(\mathbf{x}^{(i)}))$

☐ $-\log(1 - f_{\mathbf{w},b}(\mathbf{x}^{(i)}))$

Fonte: **Machine Learning Specialization**, *deeplearning.ai*, Stanford Online, Coursera.org.

A função custo que queremos minimizar na **Regressão Logística** é a média das perdas:

$$J(\vec{w}, b) = \frac{1}{m} \sum_{i=1}^m L\left(f_{\vec{w}, b}(\vec{x}^{(i)}), y^{(i)}\right)$$

onde

$$L\left(f_{\vec{w}, b}(\vec{x}^{(i)}), y^{(i)}\right) = -y^{(i)} \log\left(f_{\vec{w}, b}(\vec{x}^{(i)})\right) - (1 - y^{(i)}) \log\left(1 - f_{\vec{w}, b}(\vec{x}^{(i)})\right)$$

Sendo assim, note que podemos reescrever

$$J(\vec{w}, b) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log\left(f_{\vec{w}, b}(\vec{x}^{(i)})\right) + (1 - y^{(i)}) \log\left(1 - f_{\vec{w}, b}(\vec{x}^{(i)})\right) \right]$$

A função custo que queremos minimizar na **Regressão Logística** é a média das perdas:

$$J(\vec{w}, b) = \frac{1}{m} \sum_{i=1}^m L\left(f_{\vec{w}, b}(\vec{x}^{(i)}), y^{(i)}\right)$$

onde

$$L\left(f_{\vec{w}, b}(\vec{x}^{(i)}), y^{(i)}\right) = -y^{(i)} \log\left(f_{\vec{w}, b}(\vec{x}^{(i)})\right) - (1 - y^{(i)}) \log\left(1 - f_{\vec{w}, b}(\vec{x}^{(i)})\right)$$

Sendo assim, note que podemos reescrever

$$J(\vec{w}, b) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log\left(f_{\vec{w}, b}(\vec{x}^{(i)})\right) + (1 - y^{(i)}) \log\left(1 - f_{\vec{w}, b}(\vec{x}^{(i)})\right) \right]$$

Observação:

- O Método do Gradiente agora pode ser aplicado para encontrar quais são os parâmetros \vec{w}, b que minimizam $J(\vec{w}, b)$
- Lembrando que $J(\vec{w}, b)$ será convexa (único mínimo), ainda que o modelo seja:

$$f_{\vec{w}, b}(\vec{x}) = \frac{1}{1 + e^{-(\vec{w} \cdot \vec{x} + b)}}$$

onde $f_{\vec{w}, b}(\vec{x})$ é a probabilidade de y ser 1.

Precisamos encontrar os valores de \vec{w} , b que minimizam

$$J(\vec{w}, b) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log \left(f_{\vec{w}, b} \left(\vec{x}^{(i)} \right) \right) + (1 - y^{(i)}) \log \left(1 - f_{\vec{w}, b} \left(\vec{x}^{(i)} \right) \right) \right]$$

Sabemos que o Método do Gradiente consiste em repetir:

$$w_j = w_j - \alpha \frac{\partial}{\partial w_j} J(\vec{w}, b) \quad j = 1, \dots, n$$

$$b = b - \alpha \frac{\partial}{\partial b} J(\vec{w}, b)$$

É possível provar que, para a função $J(\vec{w}, b)$ acima, tem-se:

$$\frac{\partial}{\partial w_j} J(\vec{w}, b) = \frac{1}{m} \sum_{i=1}^m \left(f_{\vec{w}, b} \left(\vec{x}^{(i)} \right) - y^{(i)} \right) x_j^{(i)}$$

$$\frac{\partial}{\partial b} J(\vec{w}, b) = \frac{1}{m} \sum_{i=1}^m \left(f_{\vec{w}, b} \left(\vec{x}^{(i)} \right) - y^{(i)} \right)$$

Método do Gradiente para Regressão Logística consiste em repetir:

$$w_j = w_j - \alpha \left[\frac{1}{m} \sum_{i=1}^m \left(f_{\vec{w}, b}(\vec{x}^{(i)}) - y^{(i)} \right) x_j^{(i)} \right]$$

$$b = b - \alpha \left[\frac{1}{m} \sum_{i=1}^m \left(f_{\vec{w}, b}(\vec{x}^{(i)}) - y^{(i)} \right) \right]$$

Parece idêntico à Regressão Linear. Porém, devemos lembrar que:

Regressão linear:

$$f_{\vec{w}, b}(\vec{x}^{(i)}) = \vec{w} \cdot \vec{x} + b$$

Regressão Logística:

$$f_{\vec{w}, b}(\vec{x}) = \frac{1}{1 + e^{-(\vec{w} \cdot \vec{x} + b)}}$$

Quando estudamos Regressão Linear, vimos alguns conceitos importantes que também podem ser aplicados no contexto de Regressão Logística, quais sejam:

- Monitorar o Método do Gradiente (curva de aprendizado)
- Realizar implementação Vetorizada
- Escalonamento de Características

Todos estes conceitos continuam valendo agora para o contexto de Regressão Logística

Vamos agora implementar o algoritmo de Regressão Logística na prática.

Nome do arquivo que trabalharemos agora:

codigo - Regressão Logística.ipynb

Parte 1

Rode todo o “codigo - Regressão Logística.ipynb” sem fazer qualquer tipo de alteração. Certifique-se de que você o compreendeu.

Parte 2

- 1 Explique, com as suas próprias palavras, quais são os passos necessários para implementar a Regressão Logística na prática.
- 2 Faça modificações no conjunto de dados que está no código, e verifique como essas modificações alteram a fronteira de decisão do modelo estimado.